

## TP2: Expectation-Maximisation algorithm - Importance sampling

### Exercice 1: Discrete distributions

1. On cherche à générer une variable aléatoire  $X$  telle que

$$P(X = x_i) = p_i \quad i = 1, \dots, n.$$

On peut générer une variable aléatoire  $U \sim \mathcal{U}([0, 1])$ .

$$P(X \leq k) = \sum_{i=0}^k p_i = P\left(U \leq \sum_{i=0}^k p_i\right)$$

En prenant  $F = \max k$  sous contrainte  $U \leq \sum_{i=1}^k p_i$  et  $k \leq n$   
on a  $F(U) \sim X$ .

Et on a ainsi généré  $X$ .

2.3. Voir le notebook.

### Exercice 2: Gaussian mixture model and the EM algorithm

1. des paramètres dénotés par  $\theta$  sont  $(\alpha_j, \mu_j, \Sigma_j)_{j \in \{1, \dots, m\}}$ .

On note  $f_j$  la densité associée à la loi  $\mathcal{N}(\mu_j, \Sigma_j)$ .

$$f_j(x) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_j|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x - \mu_j)^T \Sigma_j^{-1} (x - \mu_j)\right)$$

Par définition, la likelihood s'écrit:

$$\begin{aligned} \mathcal{L}(x_1, \dots, x_n; \theta) &= \prod_{i=1}^n f_{\theta}(x_i) && \downarrow \text{formule des probabilités totales} \\ &= \prod_{i=1}^n \left( \sum_{j=1}^m \underbrace{f_{\theta}(x_i | Z_i = j)}_{f_j(x_i)} \underbrace{P_{\theta}(Z_i = j)}_{=\alpha_j} \right) \end{aligned}$$

$$\boxed{\mathcal{L}(x_1, \dots, x_n; \theta) = \prod_{i=1}^n \sum_{j=1}^m \alpha_j f_j(x_i)}$$



### 3. Algorithme EM:

La quantité  $Q(\theta, \theta^t)$  est un minimiseur de la log-likelihood.  
Maximiser  $Q(\theta, \theta^t)$  revient à maximiser la loglikelihood.

$$Q(\theta, \theta^t) = \sum_{i=1}^n \mathbb{E}_{Z_i \sim P_{\theta^t}(\cdot | x_i)} \left[ \ln \left( \frac{P_{\theta}(X=x_i, Z_i)}{P_{\theta^t}(Z_i | X=x_i)} \right) \right]$$

$$\begin{aligned} \text{Or, } P_{\theta^t}(X_i=x_i, Z_i) &= \sum_{j=1}^m P_{\theta^t}(X_i=x_i, Z_i=j) \\ &= \sum_{j=1}^m P_{\theta^t}(X_i=x_i | Z_i=j) P_{\theta^t}(Z_i=j) \\ &= \sum_{j=1}^m f_{\theta^t, Z_j}(x_i) \alpha_j. \end{aligned}$$

$$\begin{aligned} \text{et } P_{\theta^t}(Z_i=j | X_i=x_i) &= \frac{P(Z_i=j, X_i=x_i)}{P(X_i=x_i)} \quad (\text{formule de Bayes}) \\ &= \frac{\alpha_j f_{\theta^t, Z_j}(x_i)}{\sum_{k=1}^m \alpha_k f_{\theta^t, Z_k}(x_i)} \\ &\triangleq T_{i,j} \quad (\text{voir Notebook}) \end{aligned}$$

$$\text{Ainsi: } Q(\theta, \theta^t) = \sum_{i=1}^n \sum_{j=1}^m T_{i,j} \left( \log(f_{\theta^t, Z_j}(x_i)) + \log(\alpha_j) - \log(T_{i,j}) \right)$$

Etape E: On calcule  $Q(\theta, \theta^t)$  en calculant  $T_{i,j}$   $i=1 \rightarrow n$   
 $j=1 \rightarrow m$

On veut ensuite prendre  $\theta^{t+1} \in \arg\max_{\theta} Q(\theta, \theta^t)$ .

$$\text{ce qui revient à: } \min_{\theta} - \sum_{i=1}^n \sum_{j=1}^m T_{i,j} \left( \log(f_{\theta^t, Z_j}(x_i)) + \log(\alpha_j) \right)$$



(car  $T_{ij}(-\log T_{ij})$  ne dépend que de  $\theta^t$ ) sous contrainte :

$$\sum_{j=1}^m \alpha_j = 1.$$

On reconnaît un problème d'optimisation, dont le lagrangien s'écrit :

$$\mathcal{L}(\theta, \lambda) = - \sum_{i=1}^n \sum_{j=1}^m T_{ij} \left( \log \alpha_j + \log f_{\theta_j, \Sigma_j}(x_i) \right) + \lambda \left( \sum_{j=1}^m \alpha_j - 1 \right)$$

On cherche à vérifier l'annulation du gradient de  $\mathcal{L}$  :

$$\nabla_{\alpha_j} \mathcal{L}(\theta, \lambda) = 0 \Rightarrow \alpha_j^{t+1} = \frac{1}{n} \sum_{i=1}^n T_{ij}(\theta^t)$$

$$\nabla_{\mu_j} \mathcal{L}(\theta, \lambda) = 0 \Rightarrow \mu_j^{t+1} = \frac{1}{n \alpha_j^{t+1}} \sum_{i=1}^n x_i T_{ij}(\theta^t)$$

$$\nabla_{\Sigma_j} \mathcal{L}(\theta, \lambda) = 0 \Rightarrow \Sigma_j^{t+1} = \frac{1}{n \alpha_j^{t+1}} \sum_{i=1}^n T_{ij}(\theta^t) (x_i - \mu_j^{t+1})(x_i - \mu_j^{t+1})^T$$

Etape II : Actualiser les valeurs  $\alpha_j^{t+1}$ ,  $\mu_j^{t+1}$ ,  $\Sigma_j^{t+1}$ .

### Exercice 3 - Importance sampling

1-3. Voir le notebook.

4. A l'étape (iii) de l'algorithme Population Monte Carlo, on calcule :

$$\hat{\theta}^{(t)} \in \arg\max_{\theta} \sum_{i=1}^n \tilde{w}_i^{(t)} \log q_{\theta}(X_i^{(t)})$$

qui est une approximation de  $\arg\max_{\theta} \mathbb{E}_v [\log q_{\theta}(X_i^{(t)})]$

Comme dans l'exercice 2, on cherche à maximiser la log-likelihood  $\log q_{\theta}$ . On avait pour cela utilisé l'algorithme EM, et en gardant les mêmes notations :

$$Q(\theta, \theta^t) = \sum_{i=1}^n \tilde{w}_i^{(t)} \sum_{j=1}^m T_{ij}(\theta^t) \left( -\log \alpha_j + \log f_{\mu_j, \Sigma_j}(x_i) - \log T_{ij}(\theta^t) \right)$$

De la même manière, par annulation du gradient du Lagrangien, on obtient les paramètres suivants:

$$\alpha_j^{th} = \frac{\sum_{i=1}^n \tilde{w}_i^{(t)} T_{ij}(\theta^t)}{\sum_{k=1}^m \sum_{i=1}^n \tilde{w}_i^{(t)} T_{ik}(\theta^t)} \quad j = 1, \dots, m$$

$$\mu_j^{th} = \frac{\sum_{i=1}^n x_i \tilde{w}_i^{(t)} T_{ij}(\theta^t)}{\sum_{i=1}^n \tilde{w}_i^{(t)} T_{ij}(\theta^t)}$$

$$\Sigma_j^{th} = \frac{\sum_{i=1}^n \tilde{w}_i^{(t)} T_{ij}(\theta^t) (x_i - \mu_j^{th})(x_i - \mu_j^{th})^T}{\sum_{i=1}^n \tilde{w}_i^{(t)} T_{ij}(\theta^t)}$$